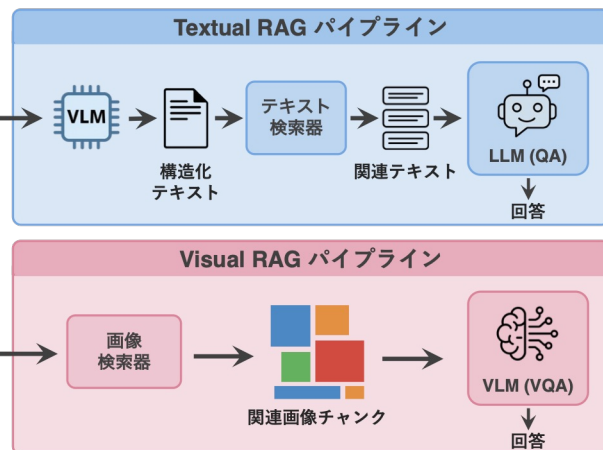



テキストおよび画像を用いた検索拡張生成のための 意味的文書レイアウト解析

植田 暢大 (NEC), 董 于洋 (SB Intuitions), Krisztián Boros, 伊藤 大輝, 世良 拓也, 小山田 昌史 (NEC)

概要：図表を含む文書ページの画像を意味的に一貫性のある領域に分割する意味的文書レイアウト解析を提案する。本解析は文書画像を用いたRAGにおいてVLMの処理精度を向上させ、精度を改善する




01 背景：Textual/Visual RAG

- Textual RAG：VLMを用いて視覚的文書をテキスト化し、通常のRAGパイプラインを実行
- Visual RAG：画像として文書のページを検索・取得し、VLMを用いてクエリに回答
- 課題：VLMは複雑なページを一度に処理しようとすると内容の欠落や誤認識が発生
▶ VLMの負荷を軽減するためページ分割が必要



02 手法：意味的文書レイアウト解析


- 既存の文書レイアウト解析は、過度なページ分割から文脈が失われるためVLMにとって最適でない
- 本研究ではトピックごとに領域をまとめる意味論的文書レイアウト解析 (SCAN) を提案し、24,000ページ以上にレイアウトラベルを付与
- これらのラベルを用いて物体検出モデルを微調整し、SCANモデルを構築



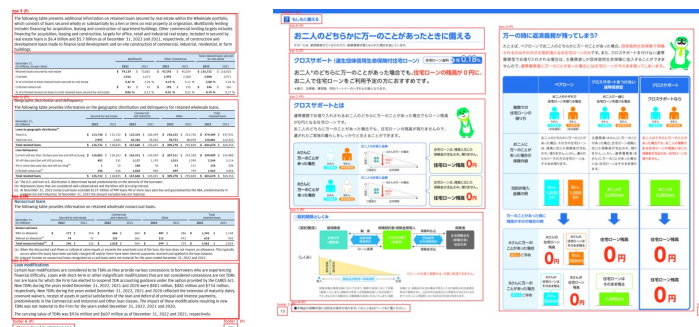
既存の文書レイアウト解析

意味的文書レイアウト解析

03 実験：RAGベンチマークにおける評価



04 解析例



05 テキスト変換コストの比較

- 画像を10枚無作為に抽出し、Qwen2.5-VL 72Bでテキスト化を実行し、処理時間を測定
- 入出力トークン総数は増加する一方、attention計算の軽量化により処理時間は減少

設定	入力トークン数	出力トークン数	チャンク数	チャンクあたりの入力トークン数	時間 (秒)
分割なし	1320.4	991.9	1.0	1320.4	68.0
分割あり	9683.1	2515.0	12.4	780.9	56.3